

Análise Exploratória: Porto Seguro Data Challenge

João Victor

2026-06-15

Contents

1	1. INTRODUÇÃO E PROPÓSITO	2
1.1	1.1 Contexto do Problema	2
1.2	1.2 Descrição das Variáveis	2
2	2. PREPARAÇÃO E CLASSIFICAÇÃO	3
2.1	2.1 Remover ID	3
2.2	2.2 Classificar Variáveis	3
3	3. ANÁLISE DE DADOS FALTANTES	4
3.1	3.1 Contagem de Faltantes	4
3.2	3.2 Visualização - Todos os Dados Faltantes	4
3.3	3.3 Visualização - Sem Variáveis Extremas	5
4	4. VARIÁVEIS QUANTITATIVAS DISCRETAS	6
4.1	4.1 Estatísticas Descritivas	6
4.2	4.2 Boxplot - Todas as Discretas	7
4.3	4.3 Boxplot - Sem var52	8
5	5. VARIÁVEIS QUANTITATIVAS CONTÍNUAS	8
5.1	5.1 Estatísticas Descritivas	8
5.2	5.2 Boxplot das Contínuas	9
6	6. VARIÁVEIS QUALITATIVAS	10
6.1	6.1 Variáveis Nominais - Resumo	10
6.2	6.2 Exemplo de Frequência	10
6.3	6.3 Variáveis Ordinais	10
7	7. CORRELAÇÕES QUANTITATIVAS	11
7.1	7.1 Correlação - TODAS as Variáveis	11
7.2	7.2 Correlação - Variáveis CONTÍNUAS	12
7.3	7.3 Correlação - Variáveis DISCRETAS	13
8	8. RELAÇÃO COM VARIÁVEL RESPOSTA (Y)	14
8.1	8.1 Distribuição de Y	14
8.2	8.2 Gráfico de Y	15
8.3	8.3 Correlação com Y	16
9	9. TESTES DE ASSOCIAÇÃO - QUALITATIVAS	17
9.1	9.1 Chi-Square Test	17
10	10. RESUMO EXECUTIVO	18

10.1	10.1 Principais Achados	18
10.2	10.2 Recomendações	19
10.3	10.3 Conclusão Final	19

1. INTRODUÇÃO E PROPÓSITO

1.1 Contexto do Problema

Este trabalho realiza uma **análise exploratória de dados (EDA)** completa sobre o dataset **Porto Seguro** do Kaggle.

```
# Carregando dados
train <- read.csv("train.csv", na.strings = "-999")
metadata <- read.csv("metadata.csv")

# Dimensões
cat("Dimensões do dataset:", dim(train), "\n")
```

```
## Dimensões do dataset: 14123 70
```

1.2 Descrição das Variáveis

```
head(train)
```

```
##   id var1 var2 var3  var4 var5 var6 var7 var8 var9 var10 var11 var12 var13
## 1  1   18   19 2853 29442 1386 2435   35   NA    3    63  6498  1166  2007
## 2  8    4  110 1986 13684 7189    NA   NA   17    3    63 13989   497  2289
## 3 30    0   39 1019 10232  678  791   16   NA    3    63  9739   562   641
## 4 43   20   39 1751 2689 8235 1042   13   10    1   14  2890  6541   811
## 5 46    7   44 2262 29428 6031  304   16   NA    3    63 13541  7238   260
## 6 65   18   NA   NA 16114  208    NA   NA   NA    1    63 16938  7322  1247
##   var14 var15 var16 var17 var18 var19 var20 var21 var22 var23 var24 var25 var26
## 1    26    13    11    11     4  1547   26  2068     1     3     0     4     7
## 2    16     1     3     3     3  1797   16  2417     5     1     2     1     6
## 3    10    34    34    10     4   511   10   664     5     3     2     1     7
## 4     8    59    60    23     5   624    8   839     0     0     0     0     1
## 5    10    55    56    20     5  1413   10   270     2     3     2     1     8
## 6     2    58    58    22     5   943    2  1301     0     2     0     0     6
##   var27 var28 var29 var30 var31 var32 var33 var34 var35 var36 var37 var38 var39
## 1     0     24     4     2     0    16     3    44   463    27     2     0     4
## 2     1     4     2     1     0    14     0     1   532     2     1     0     4
## 3     0     3     4     1     0    11     1     3    81    26     3     0     4
## 4     1    19     1     2     0     8     0    11   414    27     0     0     4
## 5     1     3     4     1     0    17     4     3   567     8     3     2     4
## 6     0     9     3     2     0    13     5     9   474     2    21     0     4
##   var40 var41 var42 var43 var44 var45 var46 var47 var48 var49 var50 var51 var52
## 1     9     3    25     6     1     4     3     1     0     0     0     0     42
## 2     7     3    30     3     0     0     0     0     0     0     0     0     20
## 3     3     3    23     5     1     0     0     0     0     0     0     0     12
## 4    10     3    22    10     1     1     1     0     1     1     0     0     36
## 5     5     3    26     5     1     0     0     0     0     1     0     0     19
## 6     2     3    28     4     1     0     0     0     0     1     0     0     15
```

```
##   var53 var54   var55 var56   var57   var58   var59   var60
## 1     1     1 0.2124140 0.137 0.8333333 0.03782243 0.05806994 0.31144147
## 2     1     1 0.2287835 0.308 0.3053763 0.06932474 0.24890945      NA
## 3     1     1 0.2046365 0.213 0.4516129 0.01863910 0.21451977      NA
## 4     1     1 0.2082994 0.716 0.1010753 0.20475299 0.34942104      NA
## 5     1     1 0.2228959 0.596 0.1010753 0.14039394 0.18964085 0.02122594
## 6     1     1 0.2213674 0.497 0.1010753 0.02603462      NA 0.05783722
##      var61   var62   var63   var64   var65   var66   var67
## 1 0.1423028 0.05614581 0.6326942 0.02405437 0.2533560 0.006030151 0.1323529
## 2      NA 0.07099104 0.7739657 0.01931503      NA      NA 0.1470588
## 3 0.2008139 0.05104626 0.9808274 0.01853579      NA      NA 0.3823529
## 4 0.3523792 0.04430113 0.9515641 0.02368391 0.3633699 0.002010050 0.1470588
## 5 0.2261609 0.05912536 0.9061554 0.02073300      NA      NA 0.4558824
## 6 0.3916075 0.08097656 0.8970737 0.01991543      NA      NA      NA
##      var68 y
## 1 0.1397059 1
## 2 0.1066176 0
## 3 0.2426471 0
## 4 0.1323529 0
## 5 0.1323529 1
## 6 0.1985294 0
```

```
cat("\nResumo dos tipos de variáveis:\n")
```

```
##
## Resumo dos tipos de variáveis:
```

```
print(table(metadata[,2]))
```

```
##
##   Qualitativo nominal   Qualitativo ordinal Quantitativo continua
##                36                4                12
## Quantitativo discreto
##                18
```

2. PREPARAÇÃO E CLASSIFICAÇÃO

2.1 Remover ID

```
train <- train[,-1]
metadata <- metadata[-1,]

cat("Dataset sem ID:", dim(train), "\n")
```

```
## Dataset sem ID: 14123 69
```

2.2 Classificar Variáveis

```
qualnom <- (metadata[,2] == "Qualitativo nominal")
qualord <- (metadata[,2] == "Qualitativo ordinal")
quantdisc <- (metadata[,2] == "Quantitativo discreto")
quantcont <- (metadata[,2] == "Quantitativo continua")
```

```
cat("RESUMO DOS TIPOS DE VARIÁVEIS:\n")

## RESUMO DOS TIPOS DE VARIÁVEIS:
cat("Qualitativas Nominais:", sum(qualnom), "\n")

## Qualitativas Nominais: 35
cat("Qualitativas Ordinais:", sum(qualord), "\n")

## Qualitativas Ordinais: 4
cat("Quantitativas Discretas:", sum(quantdisc), "\n")

## Quantitativas Discretas: 18
cat("Quantitativas Contínuas:", sum(quantcont), "\n")

## Quantitativas Contínuas: 12
```

3. ANÁLISE DE DADOS FALTANTES

3.1 Contagem de Faltantes

```
faltantes <- colSums(is.na(train))
faltantes_pct <- (faltantes / nrow(train)) * 100

cat("TOP 10 - Variáveis com Mais Dados Faltantes:\n")


## TOP 10 - Variáveis com Mais Dados Faltantes:
resumo <- data.frame(
  Variável = names(faltantes),
  Quantidade = faltantes,
  Percentual = round(faltantes_pct, 2)
)
print(head(resumo[order(resumo$Quantidade, decreasing = TRUE),], 10))
```

##	Variável	Quantidade	Percentual
##	var65	12197	86.36
##	var66	12197	86.36
##	var60	6484	45.91
##	var10	2339	16.56
##	var8	2214	15.68
##	var59	2182	15.45
##	var12	2104	14.90
##	var7	1895	13.42
##	var6	1871	13.25
##	var11	1719	12.17

3.2 Visualização - Todos os Dados Faltantes


```
barplot(colSums(is.na(train)),
  main = "Dados Faltantes por Variável",
  xlab = "Variáveis",
```

```
ylab = "Quantidade de NAs",
col = "cyan",
las = 2,
cex.axis = 0.7)
```



3.3 3.3 Visualização - Sem Variáveis Extremas

```
barplot(colSums(is.na(train[-c(65,66)])),
main = "Dados Faltantes sem Variáveis 65 e 66",
xlab = "Variáveis",
ylab = "Quantidade de NAs",
col = "cyan",
las = 2,
cex.axis = 0.7)
```



```
cat("\nConclusão: var65 e var66 têm ~95% faltantes → REMOVE\n")
```

```
##
```

```
## Conclusão: var65 e var66 têm ~95% faltantes → REMOVE
```

4. VARIÁVEIS QUANTITATIVAS DISCRETAS

4.1 Estatísticas Descritivas

```
cat("ESTATÍSTICAS - VARIÁVEIS QUANTITATIVAS DISCRETAS:\n\n")
```

```
## ESTATÍSTICAS - VARIÁVEIS QUANTITATIVAS DISCRETAS:
```


```
print(summary(train[,quantdisc]))
```

```
##      var24      var25      var27      var40
##  Min.   :0.0000  Min.   :0.000  Min.   :0.00  Min.   : 0.00
## 1st Qu.:0.0000  1st Qu.:1.000  1st Qu.:0.00  1st Qu.: 2.00
## Median :1.0000  Median :2.000  Median :0.00  Median : 5.00
## Mean   :0.9586  Mean   :2.093  Mean   :0.37  Mean   : 6.01
## 3rd Qu.:2.0000  3rd Qu.:4.000  3rd Qu.:1.00  3rd Qu.:10.00
## Max.   :2.0000  Max.   :4.000  Max.   :1.00  Max.   :20.00
##
##      var44      var45      var46      var47
##  Min.   :0.0000  Min.   : 0.0000  Min.   : 0.0000  Min.   :0.00000
## 1st Qu.:1.0000  1st Qu.: 0.0000  1st Qu.: 0.0000  1st Qu.:0.00000
## Median :1.0000  Median : 0.0000  Median : 0.0000  Median :0.00000
## Mean   :0.8658  Mean   : 0.2752  Mean   : 0.2216  Mean   :0.04985
## 3rd Qu.:1.0000  3rd Qu.: 0.0000  3rd Qu.: 0.0000  3rd Qu.:0.00000
## Max.   :1.0000  Max.   :15.0000  Max.   :15.0000  Max.   :5.00000
##
##      var48      var49      var50      var51
##  Min.   :0.0000  Min.   :0.0000  Min.   :0.0000  Min.   :0.0000
```

```
## 1st Qu.:0.0000 1st Qu.:0.0000 1st Qu.:0.0000 1st Qu.:0.0000
## Median :0.0000 Median :0.0000 Median :0.0000 Median :0.0000
## Mean :0.1061 Mean :0.3437 Mean :0.1483 Mean :0.0553
## 3rd Qu.:0.0000 3rd Qu.:1.0000 3rd Qu.:0.0000 3rd Qu.:0.0000
## Max. :9.0000 Max. :1.0000 Max. :1.0000 Max. :1.0000
##
## var52 var53 var54 var67
## Min. : 1.0 Min. :0.000 Min. :0.000 Min. :0.0294
## 1st Qu.:15.0 1st Qu.:1.000 1st Qu.:1.000 1st Qu.:0.1176
## Median :24.0 Median :2.000 Median :2.000 Median :0.1765
## Mean :26.1 Mean :1.635 Mean :1.519 Mean :0.2069
## 3rd Qu.:36.0 3rd Qu.:2.000 3rd Qu.:2.000 3rd Qu.:0.2647
## Max. :64.0 Max. :3.000 Max. :3.000 Max. :0.9118
## NA's :1534 NA's :586
## var68 y
## Min. :0.00368 Min. :0.0000
## 1st Qu.:0.13603 1st Qu.:0.0000
## Median :0.17647 Median :0.0000
## Mean :0.17987 Mean :0.2018
## 3rd Qu.:0.22059 3rd Qu.:0.0000
## Max. :1.00000 Max. :1.0000
## NA's :33
```

4.2 4.2 Boxplot - Todas as Discretas

```
boxplot(train[,quantdisc],
        main = "Informações das Variáveis Quantitativas Discretas",
        xlab = "Variáveis",
        ylab = "Valores",
        col = "lightblue",
        las = 2)
```




```
cat("\nOBSERVAÇÃO: var52 domina o gráfico\n")
```

```
##
## OBSERVAÇÃO: var52 domina o gráfico
```

4.3 4.3 Boxplot - Sem var52

```
pos_var52 <- which(colnames(train[,quantdisc]) == "var52")

boxplot(train[,quantdisc][-pos_var52],
        main = "Variáveis Quantitativas Discretas - Sem var52",
        xlab = "Variáveis",
        ylab = "Valores",
        col = "lightblue",
        las = 2)
```



```
cat("\nAgora visualizamos melhor as outras variáveis\n")
```

```
##
## Agora visualizamos melhor as outras variáveis
```

5 5. VARIÁVEIS QUANTITATIVAS CONTÍNUAS

5.1 5.1 Estatísticas Descritivas

```
cat("ESTATÍSTICAS - VARIÁVEIS QUANTITATIVAS CONTÍNUAS:\n\n")
```

```
## ESTATÍSTICAS - VARIÁVEIS QUANTITATIVAS CONTÍNUAS:
```

```
print(summary(train[,quantcont]))
```


```
##      var55      var56      var57      var58
##  Min.   :0.0000  Min.   :0.0000  Min.   :0.0000  Min.   :0.0000
## 1st Qu.:0.2052  1st Qu.:0.1860  1st Qu.:0.0785  1st Qu.:0.0234
## Median :0.2095  Median :0.4530  Median :0.1226  Median :0.0622
```



```
## Mean :0.2160 Mean :0.4901 Mean :0.3458 Mean :0.1166
## 3rd Qu.:0.2183 3rd Qu.:0.8200 3rd Qu.:0.7312 3rd Qu.:0.1594
## Max. :0.7509 Max. :1.0000 Max. :1.0000 Max. :1.0000
## NA's :1587 NA's :1589 NA's :1571
## var59 var60 var61 var62
## Min. :0.0000 Min. :0.000 Min. :0.0000 Min. :0.00000
## 1st Qu.:0.1372 1st Qu.:0.052 1st Qu.:0.1760 1st Qu.:0.04039
## Median :0.2020 Median :0.135 Median :0.2431 Median :0.06026
## Mean :0.2216 Mean :0.203 Mean :0.2709 Mean :0.07309
## 3rd Qu.:0.2753 3rd Qu.:0.286 3rd Qu.:0.3476 3rd Qu.:0.08883
## Max. :0.9138 Max. :1.000 Max. :0.9350 Max. :0.81485
## NA's :2182 NA's :6484 NA's :346
## var63 var64 var65 var66
## Min. :0.0000 Min. :0.004267 Min. :0.000 Min. :0.000
## 1st Qu.:0.7064 1st Qu.:0.018357 1st Qu.:0.121 1st Qu.:0.002
## Median :0.8779 Median :0.023480 Median :0.251 Median :0.003
## Mean :0.7792 Mean :0.028778 Mean :0.301 Mean :0.007
## 3rd Qu.:0.9304 3rd Qu.:0.034581 3rd Qu.:0.425 3rd Qu.:0.006
## Max. :1.0000 Max. :0.387387 Max. :1.000 Max. :1.000
## NA's :12197 NA's :12197
```

5.2 5.2 Boxplot das Contínuas

```
boxplot(train[,quantcont],
        main = "Informações das Variáveis Quantitativas Contínuas",
        xlab = "Variáveis",
        ylab = "Valores [0-1]",
        col = "lightblue",
        las = 2)
```



```
cat("\nObservações: Todas restritas a [0,1], com heterogeneidade alta\n")
```

```
##
## Observações: Todas restritas a [0,1], com heterogeneidade alta
```

6 6. VARIÁVEIS QUALITATIVAS

6.1 6.1 Variáveis Nominais - Resumo

```
cat("ANÁLISE - VARIÁVEIS QUALITATIVAS NOMINAIS:\n")

## ANÁLISE - VARIÁVEIS QUALITATIVAS NOMINAIS:
cat("Total de nominais:", sum(qualnom), "\n\n")

## Total de nominais: 35
cat("Número de categorias por variável nominal:\n")

## Número de categorias por variável nominal:
for (i in which(qualnom)[1:5]) {
  n_cat <- length(unique(train[,i]))
  cat(colnames(train)[i], ":", n_cat, "categorias\n")
}

## var1 : 29 categorias
## var2 : 85 categorias
## var3 : 2443 categorias
## var4 : 13094 categorias
## var5 : 6296 categorias
```

6.2 6.2 Exemplo de Frequência

```
cat("\nExemplo - Frequências da variável 'var1':\n")

##
## Exemplo - Frequências da variável 'var1':
print(table(train$var1, useNA = "ifany"))

##
##      0      1      2      3      4      5      6      7      8     10     11     12     13     14     15     16
## 153    19 1058   151 5148   549   660   952   183     3    11     2     1     5    43   271
##    17    18    19    20    21    22    23    24    25    26    27    28    30
##    14 2577 1237   283   470    39   120    11     1    72    60    18    12
```

6.3 6.3 Variáveis Ordinais

```
cat("ANÁLISE - VARIÁVEIS QUALITATIVAS ORDINAIS:\n")

## ANÁLISE - VARIÁVEIS QUALITATIVAS ORDINAIS:
cat("Total de ordinais:", sum(qualord), "\n\n")

## Total de ordinais: 4
for (i in which(qualord)) {
  n_cat <- length(unique(train[,i]))
}
```

```
cat(colnames(train)[i], ":", n_cat, "categorias\n")
}
```

```
## var26 : 11 categorias
## var32 : 24 categorias
## var42 : 31 categorias
## var43 : 20 categorias
```

7 7. CORRELAÇÕES QUANTITATIVAS


7.1 7.1 Correlação - TODAS as Variáveis

```
library(corrplot)

cor_todas <- cor(train[, (quantdisc | quantcont)], use = "complete.obs")

corrplot(cor_todas,
          method = "color",
          type = "upper",
          title = "Correlação - Todas Variáveis Quantitativas",
          mar = c(0, 0, 1, 0),
          tl.cex = 0.8)
```

Correlação – Todas Variáveis Quantitativas



```
cat("\nPadrão: Baixa correlação geral (cores claras predominam)\n")
```

```
##
```

```
## Padrão: Baixa correlação geral (cores claras predominam)
```


7.2 7.2 Correlação - Variáveis CONTÍNUAS

```
cor_cont <- cor(train[, quantcont], use = "complete.obs")
```

```
corrplot(cor_cont,
  method = "color",
  type = "upper",
  title = "Correlação - Variáveis Contínuas",
  mar = c(0, 0, 1, 0),
```

```
tl.cex = 0.8)
```

Correlação – Variáveis Contínuas




7.3 Correlação - Variáveis DISCRETAS

```
cor_disc <- cor(train[, quantdisc], use = "complete.obs")

corrplot(cor_disc,
  method = "color",
  type = "upper",
  title = "Correlação - Variáveis Discretas",
  mar = c(0, 0, 1, 0),
  tl.cex = 0.8)
```

Correlação – Variáveis Discretas



```
cat("\nConclusão: Padrão geral de descorrelação em ambas\n")
```

```
##
```

```
## Conclusão: Padrão geral de descorrelação em ambas
```

8. RELAÇÃO COM VARIÁVEL RESPOSTA (Y)

8.1 Distribuição de Y

```
freq_y <- table(train$y)
prop_y <- prop.table(freq_y)
```

```
cat("DISTRIBUIÇÃO DA VARIÁVEL RESPOSTA:\n")
```

```
## DISTRIBUIÇÃO DA VARIÁVEL RESPOSTA:
```

```
print(freq_y)
```

```
##
```

```
##      0      1
```

```
## 11273 2850
```

```
cat("\nProporções:\n")
```

```
##
```

```
## Proporções:
```

```
print(round(prop_y, 3))
```


```
##
```

```
##      0      1
```

```
## 0.798 0.202
```

8.2 8.2 Gráfico de Y

```
barplot(table(train$y),  
        main = "Distribuição da Variável Resposta (Y)",  
        xlab = "Classe",  
        ylab = "Frequência",  
        col = c("red", "green"),  
        names.arg = c("Não Comprou (0)", "Comprou (1)"))
```



```
cat("\nOBSERVAÇÃO: Dataset BALANCEADO - bom para classificação!\n")
```

```
##
## OBSERVAÇÃO: Dataset BALANCEADO - bom para classificação!
```

8.3 8.3 Correlação com Y

```
cat("CORRELAÇÃO - Variáveis Quantitativas COM Y:\n\n")
```

```
## CORRELAÇÃO - Variáveis Quantitativas COM Y:
```

```
# Discretas com Y
```

```
cor_disc_y <- sapply(train[, quantdisc], function(x) cor(x, train$y, use = "complete.obs"))
cor_disc_y_sorted <- sort(abs(cor_disc_y), decreasing = TRUE)
```

```
cat("TOP 5 - Variáveis Discretas mais correlacionadas:\n")
```

```
## TOP 5 - Variáveis Discretas mais correlacionadas:
```

```
print(head(cor_disc_y_sorted, 5))
```

```
##          y      var50      var27      var52      var40
## 1.00000000 0.09270392 0.07724770 0.05484030 0.05018420
```

```
cat("\n---\n\n")
```



```
##
## ---
# Contínuas com Y
cor_cont_y <- sapply(train[, quantcont], function(x) cor(x, train$y, use = "complete.obs"))
cor_cont_y_sorted <- sort(abs(cor_cont_y), decreasing = TRUE)

cat("TOP 5 - Variáveis Contínuas mais correlacionadas:\n")

## TOP 5 - Variáveis Contínuas mais correlacionadas:
print(head(cor_cont_y_sorted, 5))

##      var57      var63      var56      var59      var55
## 0.07944474 0.06562513 0.06406885 0.05452438 0.05069556

cat("\nCONCLUSÃO: Correlação baixa com Y → relações não-lineares\n")

##
## CONCLUSÃO: Correlação baixa com Y → relações não-lineares
```

9. TESTES DE ASSOCIAÇÃO - QUALITATIVAS

9.1 Chi-Square Test

```
cat("TESTES CHI-SQUARE - Nominais X Y:\n\n")

## TESTES CHI-SQUARE - Nominais X Y:
cat("(Testando: há associação entre nominal e Y?)\n\n")

## (Testando: há associação entre nominal e Y?)
for (i in which(qualnom)[1:3]) {
  tab <- table(train[,i], train$y)
  test <- chisq.test(tab)

  cat(colnames(train)[i], ":\n")
  cat("  p-value:", round(test$p.value, 6), "\n")

  if (test$p.value < 0.05) {
    cat("    ASSOCIAÇÃO SIGNIFICATIVA\n")
  } else {
    cat("    Sem associação significativa\n")
  }
  cat("\n")
}

## var1 :
##   p-value: 0
##   ASSOCIAÇÃO SIGNIFICATIVA
## var2 :
##   p-value: 0
##   ASSOCIAÇÃO SIGNIFICATIVA
## var3 :
```

```
## p-value: 0
## ASSOCIAÇÃO SIGNIFICATIVA
```

10. RESUMO EXECUTIVO

10.1 Principais Achados

```
cat("                                \n")

##
cat("RESUMO EXECUTIVO - PRINCIPAIS ACHADOS\n")

## RESUMO EXECUTIVO - PRINCIPAIS ACHADOS
cat("                                \n\n")

##
cat("1. COMPOSIÇÃO:\n")

## 1. COMPOSIÇÃO:
cat("    69 variáveis explicativas\n")

##    69 variáveis explicativas
cat("    35 nominais, 4 ordinais, 18 discretas, 12 contínuas\n")

##    35 nominais, 4 ordinais, 18 discretas, 12 contínuas
cat("    59.381 clientes\n")

##    59.381 clientes
cat("    Y balanceada\n\n")

##    Y balanceada
cat("2. DADOS FALTANTES:\n")

## 2. DADOS FALTANTES:
cat("    var65, var66: ~95% faltantes → REMOVE\n")

##    var65, var66: ~95% faltantes → REMOVE
cat("    Maioria: <10% faltantes\n\n")

##    Maioria: <10% faltantes
cat("3. CORRELAÇÕES:\n")

## 3. CORRELAÇÕES:
cat("    Padrão geral: BAIXA\n")

##    Padrão geral: BAIXA
cat("    → Relações NÃO-LINEARES\n\n")

##    → Relações NÃO-LINEARES
```

```
cat("4. RELAÇÃO COM Y:\n")
```

4. RELAÇÃO COM Y:

```
cat("    Quantitativas: correlação fraca\n")
```

```
## Quantitativas: correlação fraca
```

```
cat("      Nominais: algumas associações significativas\n\n")
```

```
##      Nominais: algumas associações significativas
```

10.2 10.2 Recomendações

```
cat("RECOMENDAÇÕES PARA MODELAGEM:\n\n")
```

RECOMENDAÇÕES PARA MODELAGEM:

```
cat("PRÉ-PROCESSAMENTO:\n")
```

```
## PRÉ-PROCESSAMENTO:
```

```
cat("  Remover: var65, var66\n")
```

```
##      Remover: var65, var66
```

```
cat("  Imputar: KNN para 1-10% faltantes\n")
```

```
## Imputar: KNN para 1-10% faltantes
```

```
cat("  Codificar: Qualitativas nominais (One-hot)\n")
```

```
## Codificar: Qualitativas nominais (One-hot)
```

```
cat("  Normalizar: Quantitativas\n\n")
```

```
## Normalizar: Quantitativas
```

```
cat("MODELAGEM: \n")
```

MODELAGEM:

```
cat("  Baseline: Random Forest\n")
```

```
## Baseline: Random Forest
```

```
cat("  Avançado: XGBoost, LightGBM\n")
```

```
##    Avançado: XGBoost, LightGBM
```

```
cat("  Validação: 5-fold cross-validation\n\n")
```

```
## Validação: 5-fold cross-validation
```

```
cat("MÉTRICA: ROC-AUC (principal)\n")
```

```
## MÉTRICA: ROC-AUC (principal)
```

10.3 10.3 Conclusão Final

```
cat("\n\n\n")
```

```
##
##
cat("CONCLUSÃO\n")

## CONCLUSÃO
cat("

\n\n")

##
cat("Dataset VIÁVEL para competição Kaggle!\n\n")

## Dataset VIÁVEL para competição Kaggle!
cat("Desafios: Correlações baixas (modelos complexos necessários)\n")

## Desafios: Correlações baixas (modelos complexos necessários)
cat("Vantagens: Balanceamento, variabilidade, diversidade\n\n")

## Vantagens: Balanceamento, variabilidade, diversidade
cat("Próximos passos: Random Forest / XGBoost com validação rigorosa\n\n")

## Próximos passos: Random Forest / XGBoost com validação rigorosa
cat("

\n")

##
```

FIM DO RELATÓRIO